- 1. hadoop中两个大表实现join的操作,简单描述。
 - 1. Hive中可以通过分区来减少数据量;
 - 2. 还可以通过优化HQL语句,比如只查询需要的字段,尽量避免全表、全字段查询;

2.Hive中存放是什么?

表。 存的是和hdfs的映射关系,hive是逻辑上的数据仓库,实际操作的都是hdfs上的文件,HQL就是用sql语法来写的mr程序。

3.Hive与关系型数据库的关系?

没有关系,hive是数据仓库,不能和数据库一样进行实时的CURD操作。 是一次写入多次读取的操作,可以看成是ETL工具。

4.Hive中的排序关键字有哪些?

- 1. sort by, order by, cluster by, distribute by
- 2. sort by: 不是全局排序, 其在数据进入reducer前完成排序
- 3. order by: 会对输入做全局排序,因此只有一个reducer(多个reducer无法保证全局有序).只有一个reducer,会导致当输入规模较大时,需要较长的计算时间。
- 4. cluster by: 当distribute by 和sort by的字段相同时,等同于cluster by.可以看做特殊的distribute + sort
- 5. distribute by: 按照指定的字段对数据进行划分输出到不同的reduce中

5.大表和小表join

Map side join。将小表存入内存中,将小表复制多份,让每个map task内存中保留一份(比如存放到hash table中),这样只需要扫描大表。对于大表中的每一条记录key/value,在hash table中查找是否有相同的key,如果有,则连接后输出即可。

6. 数据清洗怎么做的? 怎么用spark做数据清洗

- 1. 数据清洗的目的是为了保证数据质量,包括数据的完整性、唯一性、一致性、合法性和权威性。数据清洗的结果是对各种脏数据进行对应的处理方式,从而得到标准的、干净的、连续的数据,提供给数据统计和数据挖掘使用。
- 2. 解决数据的完整性问题:
 - a.(1) 通过其他信息不全;
 - b. (2) 通过前后数据不全;
 - c. (3) 如果实在无法不全,虽然可惜,但是还是要剔除掉进行统计。但是没必要删除,后续其他分析可能还需要。
- 3. 解决数据的唯一性问题:
 - a. (1) 根据主键进行去除,去除重复数据;
 - b. (2) 制定一系列规则,保证根据某种规则下只保存一条数据。
- 4. 解决数据权威性的问题:
 - a. 选择最权威的数据作为统计和挖掘。
- 5. 解决合法性的问题:
 - a. 设定判定规则,通过特定的规则来判断字段或者值来确定数据是否需要被清洗。

7. Hadoop中二次排序怎么做?

在hadoop中一般都是按照key进行排序的,但是有时候还需要按照value进行排序。

有两种办法进行二次排序: buffer and int memory sort和value-to-key conversion。

- a. Buffer and in memory sort主要是在reduce()函数中,将每个key对应的value值保存下来,进行排序。但是缺点在于可能会出现out of memory。
- b. Value-to-key conversion主要思想是将key和value拼接成一个组合key,然后进行排序,这样reduce()函数获取的结果就 实现了先按照key排序,然后按照value进行排序。需要注意的是,用户需要自己实现paritioner,以便只按照key进行数 据划分。

8. hadoop常见的join操作?

- (1) reduce side join: 是最简单的join操作,主要是在reduce端进行join操作;
- (2) Map side join: 之所以存在reduce side join, 是因为在map端不能获得需要连接的全部的字段。Reduce side join比较低
- 效,因为shuffle传输数据需要消耗大量的性能。
- (3) Semijoin: 半连接,对于reduce side join, 跨机器的数据传输量特别大,成为join的一个瓶颈。如果能在map端过滤掉不会参加join的数据,那么可以大大节省网络IO。

9. hive优化有哪些?

(1) 数据存储及压缩。

针对hive中表的存储格式通常有orc和parquet, 压缩格式一般使用snappy。相比与textfile格式表, orc占有更少的存储。因为hive底层使用MR计算架构,数据流是hdfs到磁盘再到hdfs,而且会有很多次,所以使用orc数据格式和snappy压缩策略可以降低IO读写,还能降低网络传输量,这样在一定程度上可以节省存储,还能提升hql任务执行效率;

(2) 通过调参优化。

并行执行,调节parallel参数;

调节jvm参数, 重用jvm;

设置map、reduce的参数;

开启strict mode模式;

关闭推测执行设置。

(3) 有效地减小数据集

将大表拆分成子表;

结合使用外部表和分区表。

(4) SOL优化

大表对大表: 尽量减少数据集, 可以通过分区表, 避免扫描全表或者全字段;

大表对小表:设置自动识别小表,将小表放入内存中去执行。

10. 分析函数?

row_number() over(partition by regionX order by nameX desc) as tn 1 93;2 90;3 90 排名是连续的,相同的分数会有排名先后,前100名只有100个

rank() over(partiition by regionX order by nameX desc) as tn 1 93;2 90;2 90;4 89 排名不是连续的,相同的分数是同名次,前100 名只有100个

dense rank() over() 1 93;2 90;3 89排名是连续的,相同的分数是同名次,前100名可能多于100个

11. 分析下hive数据倾斜问题,有什么解决方案?

- 1. 倾斜原因: map输出数据按Key Hash分配到reduce中,由于key分布不均匀、或者业务数据本身的特点。等原因造成的 reduce上的数据量差异过大。
 - 1.1)key分布不均匀
 - 1.2)业务数据本身的特性
 - 1.3)SQL语句造成数据倾斜
 - 2. 解决方案:

1>参数调节:

- 1 hive.map.aggr=true
- p hive.groupby.skewindata=true

有数据倾斜的时候进行负载均衡,当选项设定为true,生成的查询计划会有两个MR Job。第一个MR Job中,Map的输出结果集合会随机分布到Reduce中,每个Reduce做部分聚合操作,并输出结果,这样处理的结果是相同Group By Key有可能被分发到不同的Reduce中,从而达到负载均衡的目的;第二个MR Job在根据预处理的数据结果按照 Group By Key 分布到Reduce中(这个过程可以保证相同的 Group By Key 被分布到同一个Reduce中),最后完成最终的聚合操作。

2>SQL语句调节:

1)选用join key 分布最均匀的表作为驱动表。做好列裁剪和filter操作,以达到两表join的时候,数据量相对变小的效果。

2)大小表Join: 使用map join让小的维度表(1000条以下的记录条数)先进内存。在Map端完成Reduce。

3)大表Join大表:把空值的Key变成一个字符串加上一个随机数,把倾斜的数据分到不同的reduce上,由于null值关联不上,处理后并不影响最终的结果。

4) count distinct大量相同特殊值: count distinct时,将值为空的情况单独处理,如果是计算count distinct,可以不用处理,直接过滤,在做后结果中加1。如果还有其他计算,需要进行group by,可以先将值为空的记录单独处理,再和其他计算结果进行union.

12. 请说明hive中 sort by , order by , cluster by , distribute by各代表什么意思?

- 1. order by: 会对输入做全局排序,因此只有一个reducer(多个reducer无法保证全局有序).只有一个reducer,会导致当输入规模较大时,需要较长的计算时间。
- 2. sort by: 不是全局排序, 其在数据进入reducer前完成排序
- 3. distribute by: 按照指定的字段对数据进行划分输出到不同的reduce中
- 4. cluster by: 除了具有distribute by 的功能外还兼具sort by 的功能

13. 描述数据中的null,在hive底层如何存储?

null在hive底层默认是用"\N"来存储的,所以在sqoop到mysql之前需要将为null的数据加工成其他字符,否则sqoop提示错误

14. Hive中 split、coalesce以及collect list函数的用法?

- 1. split将字符串转化为数组
- 2. coalesce(T v1,T v2,...) 返回参数中的第一个非空值;如果所有值都为null,那么返回null
- 3. collect_list列出该字段所有的值,不去重 select collect_list(id) from table;

15.如何将文件导入到hive表中?

1 load data local inpath '/a.txt' overwrite into table test partition(xx='xx')

16.Hive的分组方式?

- 1. row_number() 是没有重复值的排序(即使两天记录相等也是不重复的),可以利用它来实现分页
- 2. dense_rank() 是连续排序,两个第二名仍然跟着第三名
- 3. rank() 是跳跃排序的,两个第二名下来就是第四名

17. 请把下一语句用hive方式实现?

- 1 SELECT a.key,a.value
- ₂ FROM a
- 3 WHERE a.key not in (SELECT b.key FROM b)

答案:

select a.key,a.value from a where a.key not exists (select b.key from b)

18.Hive内外部表的区别

删除表是否影响外部数据 内部表影响,外部表不影响

19. Hive如何做到权限管理

hive下可以修改配置后创建用户管理,但是仅仅是为了防止误操而已,如果要真的为了安全操作建议使用Kerberos(和 Hadoop相同)

20.说说对桶表的理解

对数据的细化 取模分开存储数据,提高查询效率

21.hive有哪些保存元数据的方式,有什么特点

1) Single User Mode:

默认安装hive,hive是使用derby内存数据库保存hive的元数据,这样是不可以并发调用hive的,这种模式时hive默认

的存储模式。

2) Multi User Mode:

通过网络连接到一个数据库中,是最经常使用到的模式。假设使用本机mysql服务器存储元数据。这种存储方式需要在本地运行一个mysql服务器,并作如下配置(需要将mysql的jar包拷贝到\$HIVE_HOME/lib目录下)。

3) Remote Server Mode:

在服务器端启动一个 MetaStoreServer,客户端利用 Thrift 协议通过 MetaStoreServer 访问元数据库。

22.hive能建多个库吗

可以

23.请谈一下hive的特点是什么? hive和RDBMS有什么异同?

hive是基于Hadoop的一个数据仓库工具,可以将结构化的数据文件映射为一张数据库表,并提供完整的sql查询功能,可以将sql语句转换为MapReduce任务进行运行。其优点是学习成本低,可以通过类SQL语句快速实现简单的MapReduce统计,不必开发专门的MapReduce应用,十分适合数据仓库的统计分析。

24.hive 是如何实现分区的?

1. 建表语句:

create table tablename (id) partitioned by (dt string)

2. 增加分区:

alter table tablenname add partition (dt = '2016-03-06')

3. 删除分区:

alter table tablename drop partition (dt = '2016-03-06')

25. hive 相对于 Oracle 来说有那些优点?

- 1) 存储, hive 存储在 hdfs 上, oracle 存储在本地文件系统。
- 2) 扩展性, hive 可以扩展到数千节点, oracle 理论上只可扩展到 100 台左右。
- 3) 单表存储,数据量大 hive 可以分区分桶,oracle 数据量大只能分表。

26.Hive 的 sort by 和 order by 的区别!

- 1. order by 会对输入数据做全局排序,只有一个 reduce,数据量较大时,很慢。
- 2. sort by 不是全局排序,只能保证每个 reduce 有序,不能保证全局有序,需设置mapred.reduce.tasks>1。